

MACHINE LEARNING IN SOC

Membangun Anomaly Baselines, Behavioral Analytics, dan Eksekusi UEBA di Lingkungan Enterprise.

Disusun Oleh: **Rizki Angga Pratama**
L2 SOC Analyst

HAK CIPTA & DISCLAIMER

Machine Learning in SOC: Anomaly Baselines & Behavioral Analytics
Edisi Enterprise (50 Halaman)

Disusun oleh: Rizki Angga Pratama, S. Kom, C. Pro

Dokumen ini adalah panduan konseptual dan teknis yang membongkar "Kotak Hitam" *Machine Learning* (ML) di dalam platform SIEM (seperti Elastic Security dan Splunk UBA). Buku ini mengajarkan *Security Engineers* cara merancang deteksi yang melampaui aturan statis (*rules*) untuk menangkap anomali perilaku.

> **Catatan Operasional:**
> Model ML bergantung 100% pada kualitas data (*Data Quality*). Strategi dan kueri KQL yang dibahas dalam dokumen ini mengasumsikan bahwa seluruh log jaringan, *endpoint*, dan identitas perusahaan Anda telah dinormalisasi menggunakan skema standar (seperti *Elastic Common Schema / ECS*).

Filosofi Desain:
Buku ini dirancang menggunakan estetika *Neural Network* (Obsidian Black, Neon Pink, dan Purple). Warna-warna ini merepresentasikan persimpangan antara Ilmu Data (*Data Science*) dan Keamanan Siber, menyoroti koneksi antar-entitas, kurva probabilitas matematis, dan kecerdasan buatan.

© 2026 Hak cipta dilindungi undang-undang. Panduan Deteksi Tingkat Lanjut SOC.

KATA PENGANTAR

Sejak lahirnya sistem SIEM (*Security Information and Event Management*), analis SOC beroperasi menggunakan **Aturan Berbasis Logika (Rule-Based Detection)**. Kita menulis kueri KQL: *"Jika Pengguna gagal masuk 5 kali dalam 1 menit, hasilkan peringatan."* Ini disebut *Thresholding* (Ambang Batas) statis.

Pendekatan statis ini fantastis untuk mendeteksi ancaman yang *Sudah Diketahui* (*Known Threats*). Namun, ia gagal total saat menghadapi ancaman yang *Belum Diketahui* (*Unknown Threats*) dan penyusup yang sabar. Peretas modern tidak melakukan *Brute Force* 5 kali semenit. Mereka mencuri kata sandi sah, masuk sekali (berhasil), dan perlahan menyalin (*copy*) fail rahasia setiap malam minggu.

Bagaimana Anda menulis *Rule* statis untuk membedakan "Karyawan yang lembur mengerjakan presentasi" dengan "Peretas yang sedang mengunduh basis data perusahaan"? Jika mereka menggunakan alat yang sama dan kredensial yang sah, logika SIEM tradisional buta.

Di sinilah **Machine Learning (ML)** dan **User Entity Behavioral Analytics (UEBA)** mengambil alih. Kita berhenti memberi tahu mesin apa yang harus dicari. Sebagai gantinya, kita meminta mesin untuk mempelajari apa itu "Normal", lalu memerintahkannya untuk berteriak setiap kali sesuatu berubah menjadi "Tidak Normal".

E-book 50 halaman ini akan mengubah Anda dari seorang penulis *Rule* SIEM, menjadi seorang *Cybersecurity Data Scientist*. Kita akan merancang *Baselines*, memetakan kelompok setara (*Peer Groups*), dan mengintegrasikan skor probabilitas ML ke dalam otomatisasi respons (SOAR) Anda.

— Rizki Angga Pratama

Author

DAFTAR ISI (1/2)

BAGIAN I: Fondasi Machine Learning di SOC

Bab 1.1 Kematian Aturan Statis (Rules) Hlm. 7

Bab 1.2 Supervised vs Unsupervised Learning Hlm. 8

Bab 1.3 Kualitas Data: Garbage In, Garbage Out Hlm. 9

Bab 1.4 Feature Engineering dalam Log SecOps Hlm. 10

Bab 1.5 Clustering vs Classification Hlm. 11

Bab 1.6 Dilema False Positive di ML Hlm. 12

BAGIAN II: Membangun Anomaly Baselines

Bab 2.1 Konsep Matematis Baseline Hlm. 14

Bab 2.2 Time-Series Analysis di Jaringan Hlm. 15

Bab 2.3 Menangani Musiman (Seasonality/Weekends) Hlm. 16

Bab 2.4 Deteksi Data Exfiltration (Bandwidth) Hlm. 17

Bab 2.5 Rare Process Execution (LOLBins) Hlm. 18

Bab 2.6 KQL: Memvalidasi Temuan Rare Process Hlm. 19

Bab 2.7 Domain Generation Algorithms (DGA) Hlm. 20

Bab 2.8 Analisis Entropi Karakter DNS Hlm. 21

Bab 2.9 Korelasi Vektor Multi-Anomali Hlm. 22

DAFTAR ISI (2/2)

BAGIAN III: User Entity Behavioral Analytics (UEBA)

Bab 3.1 Apa itu UEBA? Hlm. 24

Bab 3.2 Membedakan Analitik User vs Entity Hlm. 25

Bab 3.3 Peer Group Profiling (Rekan Grup) Hlm. 26

Bab 3.4 Mekanika Risk Scoring (Skor Risiko) Hlm. 27

Bab 3.5 Berburu Insider Threat (Ancaman Internal) Hlm. 28

Bab 3.6 ML Mendeteksi Impossible Travel Hlm. 29

Bab 3.7 Anomali Working Hours (Waktu Kerja) Hlm. 30

Bab 3.8 Privileged Account Monitoring Hlm. 31

Bab 3.9 Sinergi UEBA dengan Zero Trust Hlm. 32

BAGIAN IV: Implementasi ML di Platform SIEM

Bab 4.1 Ekosistem Elastic ML Hlm. 34

Bab 4.2 Mengonfigurasi Single Metric Job Hlm. 35

Bab 4.3 Multi-Metric & Population Jobs Hlm. 36

Bab 4.4 Konsep Influencers di ML Elastic Hlm. 37

Bab 4.5 Splunk UBA (User Behavior Analytics) Hlm. 38

Bab 4.6 KQL: Kueri Indeks .ml-anomalies-* Hlm. 39

Bab 4.7 Bring Your Own Model (BYOM) Hlm. 40

Bab 4.8 NLP & Log Parsing Otomatis Hlm. 41

BAGIAN V: Operasionalisasi ML Alerts

Bab 5.1 Alert Fatigue di Dunia ML Hlm. 43

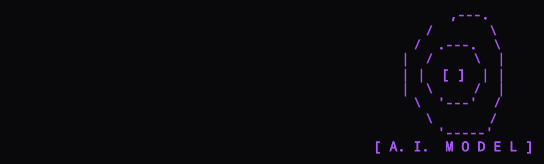
Bab 5.2 Tuning Model & Feedback Loops Hlm. 44

Bab 5.3 Suppression Windows (Jeda Pemeliharaan) Hlm. 45

Bab 5.4 Integrasi ML Risk Score dengan SOAR Hlm. 46

Bab 5.5 Masa Depan: Dari ML menuju LLMs Hlm. 47

Glosarium ML SecOps (A-M) Hlm. 48



BAGIAN I

Fondasi Machine Learning
di Security Operations Center

BAB 1: EVOLUSI ANALITIK

1.1 Kematian Aturan Statis (Rules)

Fondasi utama dari SOC tradisional adalah *Correlation Rules*. Analis menggunakan kepandaian manusia untuk mendikte SIEM apa yang harus dicari: *"Jika proses A dijalankan, dan mengandung parameter B, maka tembakkan Alert C."*

Pendekatan ini memiliki batas arsitektural yang parah:

- **Skalabilitas Terbatas:** Anda tidak mungkin menulis 5.000 aturan untuk mencakup semua skenario *malware* di dunia. Semakin banyak aturan, SIEM semakin lambat memprosesnya (*CPU bottleneck*).
- **Kebutaan Konteks:** Aturan statis tidak memiliki ingatan (*Memory*). Ia tidak tahu bahwa Pengguna X biasanya mengunduh 2 GB data setiap hari Jumat sore karena pekerjaannya. Aturan statis akan membunyikan alarm terus-menerus (*False Positive*).
- **Ancaman Zero-Day:** Anda tidak bisa menulis aturan KQL untuk alat peretasan baru yang bahkan namanya belum pernah Anda dengar dan *Hash*-nya belum ada di *VirusTotal*.

Para peretas mengetahui batasan ini. Mereka merancang *malware* untuk membaur dan tetap berada di bawah ambang batas (*thresholds*) logika manusia. Kita butuh matematika untuk menangkap mereka.

1.2 Supervised vs Unsupervised Learning

Di SOC, *Machine Learning* umumnya terbagi dalam dua keluarga algoritma besar, dan keduanya memiliki tujuan yang sepenuhnya berbeda dalam perburuan ancaman.

PARAMETER	SUPERVISED LEARNING (TERARAH)	UNSUPERVISED LEARNING (TAK TERARAH)
Konsep	Belajar dari data yang sudah diberi label oleh manusia (Contoh: Ini adalah *Malware*, ini adalah *Bersih*).	Belajar dari data mentah tanpa label. Mesin mencari pola, kelompok, dan pencilan (*Outliers*) sendiri.
Penggunaan SOC	Membedah DGA Domain, Deteksi Phishing di Email, Analisis Statis Antivirus EDR.	**UEBA (Behavioral Analytics)**, Deteksi Eksfiltrasi, Pencarian Proses Langka.
Kekuatan	Sangat akurat untuk ancaman yang mirip dengan ancaman masa lalu.	Mampu mendeteksi **Unknown Unknowns** (Serangan Zero-Day baru).

Buku ini akan sangat berfokus pada **Unsupervised Learning**, karena algoritma inilah yang berada di balik mesin *Anomaly Detection* dan UEBA di sebagian besar SIEM (seperti Elastic dan Splunk).

1.3 Kualitas Data (Garbage In, Garbage Out)

Rahasia terbesar yang sering disembunyikan vendor SIEM adalah ini: **Machine Learning hanyalah penguat (Amplifier). Jika data Anda berantakan, ML akan memperkuat kekacauan tersebut, bukan memperbaikinya.**

Konsep ini dikenal sebagai *Garbage In, Garbage Out (GIGO)*. Jika Anda menyalakan fitur Elastic ML untuk mencari *"Rare Process Execution"* (Proses Langka), tetapi log *Endpoint* Anda belum dinormalisasi (satu log menyebutnya `process.name`, log lain menyebutnya `exe_name`), maka ML akan menghasilkan ribuan *False Positive* yang tidak masuk akal.

Sebelum menghidupkan 1 (satu) saja *ML Job*, seorang *Detection Engineer* harus bekerja sama dengan *Data Engineer* untuk menerapkan skema standar seperti **Elastic Common Schema (ECS)** atau **Splunk CIM (Common Information Model)**. Nama *Field*, tipe data (*String vs Integer*), dan pemformatan tanggal waktu (*Timestamps*) harus absolut konsisten di seluruh triliunan baris log.

1.4 Feature Engineering dalam Log SecOps

Saat Anda memberikan log mentah (teks JSON panjang) ke algoritma, mesin tidak mengerti teks. Mesin hanya mengerti angka dan vektor. Proses mengubah data mentah SOC menjadi metrik yang dapat dihitung oleh ML disebut **Feature Engineering**.

Sebagai contoh, mendeteksi *Malware Command & Control (C2)* yang menyamar sebagai *traffic* HTTP biasa. Analis manusia melihat URI: `/api/v1/update?id=x7q9P2z`. Analis mungkin tidak curiga.

Namun, dalam *Feature Engineering*, SIEM mengekstrak fitur matematis sebelum memberikan log ini ke algoritma ML:

- **Feature 1 (Rasio Konsonan):** Berapa rasio huruf konsonan terhadap vokal dalam URI tersebut? (*Malware* C2 sering *random*).
- **Feature 2 (Entropi String):** Seberapa acak karakter tersebut (Skor Shannon Entropy)?
- **Feature 3 (Frekuensi Waktu):** Apakah IP ini menghubungi URI tersebut tepat setiap 60 detik (*Beaconing/Jitter*)?

Berdasarkan fitur-fitur matematis inilah (bukan dari membaca string mentahnya) algoritma ML mengkategorikan lalu lintas sebagai normal atau ancaman.

1.5 Clustering vs Classification

Di dalam *Unsupervised Learning*, teknik paling berguna bagi analis SOC adalah **Clustering (Pengelompokan)**.

Bayangkan Anda memiliki 1.000 log aktivitas jaringan. *Clustering* (seperti algoritma K-Means atau DBSCAN) akan meletakkan 1.000 log tersebut di atas grafik tiga dimensi dan mencari titik yang saling berdekatan. Mereka yang saling berkumpul (*Cluster*) dianggap sebagai aktivitas "Normal".

Aktivitas yang berada di pinggiran, jauh dari kelompok utama, disebut sebagai **Outliers (Pencilan)**. Inilah yang diangkat menjadi sebuah Anomali di *Dashboard* SIEM Anda.

Sebaliknya, **Classification** (Klasifikasi) digunakan di *Supervised Learning*. Ia memisahkan *File A* ke keranjang "Malware" dan *File B* ke keranjang "Aman" berdasarkan model yang sudah dilatih dengan jutaan sampel virus masa lalu. Ini adalah tulang punggung dari *Next-Gen Antivirus (NGAV)*.

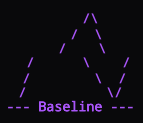
1.6 Dilema False Positive di ML

Manajemen harus memahami: **Machine Learning bukanlah peluru perak. Anomali (Ketidaknormalan) TIDAK SAMA DENGAN Malicious (Jahat).**

Jika seorang Karyawan Penjualan yang selalu bekerja Senin-Jumat tiba-tiba *login* di hari Minggu jam 2 pagi untuk mencari dokumen, algoritma ML (*Unsupervised*) akan berteriak keras: *"ANOMALI SKOR 99!"*. Secara matematis, ML benar. Itu adalah pencilan mutlak dari kebiasaan historisnya.

Namun secara keamanan (*Security*), karyawan itu sah (*Benign*). Tidak ada peretasan yang terjadi. Ini adalah *False Positive* berbasis konteks.

Inilah sebabnya analis SOC manusia tidak akan digantikan oleh ML. ML bertugas **menyaring 10 Juta log menjadi 10 anomali menarik**. Analis manusiatersebut yang memegang *Konteks Bisnis* ("Oh, ini akhir bulan, pantas dia lembur") untuk menutup tiket insiden tersebut.



BAGIAN II

Membangun Anomaly Baselines
& Analitik Waktu-Deret

BAB 2: ANOMALY BASELINES

2.1 Konsep Matematis Baseline

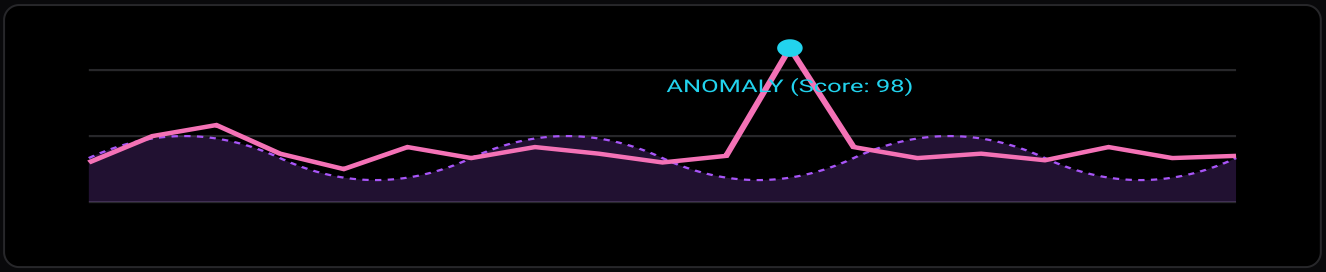
Sebelum kita bisa mendeteksi kelainan (*Anomaly*), sistem harus tahu apa itu kewajaran (*Normal*). Kewajaran ini diwakili oleh sebuah profil matematis yang disebut **Baseline**.

Sebuah *Baseline* tidak dibuat dalam sehari. Untuk mendapatkan akurasi yang tinggi, model ML (seperti yang ada di Elastic Security) membutuhkan periode pembelajaran (*Learning/Training Period*) dari data historis, biasanya antara **14 hingga 30 hari** log nyata perusahaan Anda.

Selama periode 14 hari pertama ini, *ML Job* berjalan di latar belakang (tanpa menghasilkan peringatan apa pun ke SOC). Ia menghitung Rata-rata (*Mean*), Varians, dan Deviasi Standar dari metrik yang Anda minta (misal: jumlah volume data yang keluar ke internet). Setelah kurva distribusi normal terbentuk, barulah ia siap dioperasionalkan (*Operationalized*).

2.2 Time-Series Analysis di Jaringan

Deteksi anomali jaringan didominasi oleh **Time-Series Analysis** (Analisis Waktu-Deret). Ini adalah ilmu membedah data yang memiliki penanda waktu (*Timestamp*) berkelanjutan.



Pada grafik di atas, garis ungu (putus-putus) adalah prediksi masa depan yang dibuat oleh ML berdasarkan masa lalu. Area berbayang adalah batas kewajaran (*Confidence Interval*). Selama lalu lintas jaringan asli (garis merah muda) bergelombang di dalam area ungu, tidak ada peringatan (*Alert*) yang dibangkitkan.

Saat titik merah muda meroket keluar dari batas pita ungu (titik *Cyan*), model matematis pecah, dan peringatan *High Severity* segera dikirim ke dasbor analis SOC.

2.3 Menangani Musiman (Seasonality/Weekends)

Alasan *Thresholding* statis gagal adalah karena ia tidak mengerti "Kalender". Logika aturan statis: *"Jika jumlah login < 100 per jam, maka waspada ada masalah jaringan."* Aturan statis ini akan hancur dan membunyikan alarm setiap akhir pekan (Sabtu/Minggu) saat tidak ada karyawan di kantor.

Model Waktu-Deret ML (seperti algoritma *Bucketspan* Elastic) memiliki **Seasonality Awareness (Kesadaran Musiman)**. ML memahami ritme harian (*Diurnal*) dan ritme mingguan perusahaan Anda.

ML otomatis merendahkan *Baseline* prediksi ke titik hampir nol pada hari Sabtu dan Minggu. Jika pada hari Minggu tiba-tiba terdapat 50 *login* dari VPN (yang pada hari kerja 50 *login* dianggap sangat normal dan kecil), ML akan langsung meledakkan peringatan krisis, karena 50 *login* di saat *Baseline* bernilai 0 adalah sebuah **Anomali Musiman Mutlak**.

2.4 Deteksi Data Exfiltration (Bandwidth)

Salah satu penerapan paling mematikan dari *ML Time-Series* adalah mendeteksi pencurian data perusahaan (**Data Exfiltration**) oleh *Ransomware* (seperti LockBit) sebelum mereka mengeksekusi tahapan enkripsi *disk*.

Menangkap eksfiltrasi sulit karena pelaku sering menggunakan IP *Cloud* publik (AWS/Azure) yang sah, atau layanan (seperti *Mega.nz/Google Drive*) yang tidak diblokir oleh *Firewall* perusahaan.

Solusi SOC: Kita membangun *ML Job* yang memantau `high_count` pada *field* `network.bytes_written` (Total *Byte* yang dikirim keluar), dan mengelompokkannya (*Split By*) berdasarkan `source.ip` (IP Karyawan/Server).

Jika IP peladen *Database* yang biasanya hanya mengirim balasan 10 Megabyte per jam ke peladen *Web Front-End*, tiba-tiba mencoba mengirim 450 Gigabyte ke sebuah IP eksternal di internet, ML akan menabrak *Baseline* atasnya dan SOC dapat memotong koneksi jaringan peladen tersebut (*Isolate Host*) via SOAR sebelum pencurian 1 Terabyte data nasabah selesai diunggah.

2.5 Rare Process Execution (LOLBins)

Tidak semua ML berurusan dengan volume angka. Kita juga menggunakan ML untuk menemukan kejadian langka melalui **Rare Pattern Analysis**.

Pelaku ancaman (*Threat Actors*) jarang membawa alat peretas khusus (*malware.exe*) ke dalam *laptop* korban karena akan ditangkap oleh Antivirus. Mereka menggunakan **Living off the Land Binaries (LOLBins)**—aplikasi bawaan Windows yang legal seperti `certutil.exe`, `powershell.exe`, atau `vssadmin.exe` untuk melakukan peretasan.

Secara statis, mengeksekusi `certutil.exe` adalah normal bagi layanan pembaruan (*update*) Windows. Namun ML membangun daftar semua proses yang biasa dijalankan di setiap departemen. Jika akun dari departemen *Marketing* tiba-tiba mengeksekusi `certutil.exe -urlcache -split -f` (perintah untuk mengunduh fail dari internet), ML akan menyadari bahwa ini adalah **Proses yang Sangat Langka (Rare)** untuk profil Karyawan *Marketing* dan menandainya sebagai indikator kompromi (*IoC*).

2.6 KQL: Memvalidasi Temuan Rare Process

Saat ML *Rare Process* berteriak, analis SOC harus melakukan pembuktian (*Validation*) ke dalam SIEM menggunakan KQL mentah untuk melihat konteks proses (*Parent-Child Process Tree*) dari peringatan tersebut.

```
/* SIEM KQL: Triase Manual setelah ML Alert (Rare Process) */ event.category: "process" AND event.type: "start" AND host.name: "LT-MKT-991" /* Host yang dilaporkan oleh ML */ /* Cari rantai proses mencurigakan di sekitar jendela waktu alert */ | keep @timestamp, process.parent.name, process.name, process.command_line, user.name | sort @timestamp asc
```

Dari hasil tabel KQL tersebut, analis mungkin melihat bahwa induk prosesnya adalah `winword.exe` (Microsoft Word) yang menelurkan (*Spawn*) `cmd.exe`, yang kemudian menelurkan proses langka (`certutil.exe`) tersebut. Ini adalah rantai mutlak serangan *Phishing Macro* (Malicious Document), mengonfirmasi bahwa insting anomali mesin ML 100% akurat.

2.7 Domain Generation Algorithms (DGA)

Serangan modern (terutama *Malware Command & Control / C2* dan *Ransomware*) menggunakan **Domain Generation Algorithms (DGA)** untuk berkomunikasi dengan peretas. Daripada *malware* menghubungi satu domain tetap (misal: `hacker-c2.com`) yang mudah diblokir oleh SOC, *malware* menghasilkan 1.000 domain acak setiap hari (misal: `xqjz99kla1.net`, `zxc901q.org`).

Karena domain ini berubah setiap detik dan tidak ada di buku hitam manapun (*Threat Intel Feeds*), aturan statis (*Firewall Blacklist*) benar-benar tidak berguna.

SOC menyebarkan model **Supervised Machine Learning (Klasifikasi DGA)**. Model ini telah dilatih (*Trained*) di laboratorium dengan jutaan domain normal (seperti `google.com`, `detik.com`) dan jutaan domain acak virus masa lalu. Model ini bekerja seketika (*Inline*) saat menerima kueri log DNS.

2.8 Analisis Entropi Karakter DNS

Bagaimana model klasifikasi DGA membedakan domain legal vs *malware*? Ia menggunakan fungsi matematis, salah satunya adalah **Shannon Entropy** (Skor keacakan karakter).

Model menganalisis parameter (*Features*) seperti:

- **Skor Entropi:** `google.com` memiliki skor rendah (mudah diucapkan manusia). `x8q9z-1k.com` memiliki entropi sangat tinggi.
- **Rasio Huruf/Angka:** Berapa banyak angka yang disisipkan di antara huruf?
- **N-Gram Analysis (Bigram/Trigram):** Kombinasi dua huruf berurutan. Dalam bahasa Inggris/Indonesia, huruf "t" diikuti "h" (*th*) sangat wajar. Huruf "x" diikuti "q" (*xq*) hampir tidak pernah ada di kata sah manusia.

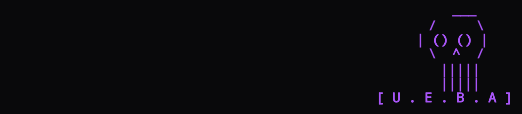
Jika model mengeluarkan skor Probabilitas > 95% bahwa `dns.question.name` adalah DGA, SOAR akan mengambil log tersebut dan menginstruksikan *DNS Sinkhole* (seperti Cisco Umbrella) untuk meracuni (*Block*) resolusi domain tersebut di seluruh perusahaan detik itu juga.

2.9 Korelasi Vektor Multi-Anomali

Sebuah anomali ML tunggal sering kali berujung pada *False Positive*. Jika seorang karyawan *Marketing* menjalankan proses langka (Satu Anomali), bisa jadi ia sedang menginstal perangkat lunak pengeditan video yang belum pernah ada di perusahaan.

Keajaiban tingkat atas dari SOC (*Maturity Level 3*) adalah **Korelasi Multi-Anomali**. Kita menggabungkan (JOIN) beberapa peringatan mesin ke dalam satu kueri *Alerting* EQL tingkat atas (*Meta-Alert*).

> **Logika Meta-Alert: The 3-Strike Rule**
> JIKA dalam jendela 1 jam, sebuah mesin (Host IP) memicu:
> 1. **ML Job A:** *Rare Process Execution* (Eksekusi `powershell.exe` yang tidak wajar).
> 2. **ML Job B:** *High Bandwidth Variance* (Lonjakan unggahan data raksasa).
> 3. **ML Job C:** *DGA DNS Request* (Meminta akses ke `x901zka.info`).
>
> MAKA: Naikkan tingkat bahaya menjadi KIAMAT (Critical). Peluang tiga algoritma berbeda melakukan *False Positive* pada mesin yang sama di jam yang sama adalah 1 berbanding 1 Juta. Mesin tersebut 100% terinfeksi *Ransomware / RAT* aktif.



BAGIAN III

User Entity Behavioral Analytics
(Perburuan Identitas Cerdas)

BAB 3: BEHAVIORAL ANALYTICS

3.1 Apa itu UEBA?

User and Entity Behavior Analytics (UEBA) adalah penggunaan pembelajaran mesin (*Machine Learning*) bukan untuk melacak metrik jaringan yang abstrak (seperti *Bandwidth*), melainkan untuk melacak entitas individu. Singkatnya: Ini adalah mesin pengintai perilaku psikologis di dunia siber.

UEBA menjawab pertanyaan: *"Apakah tingkah laku pengguna Budi di hari Selasa ini, sesuai dengan tingkah laku Budi di masa lalu, dan sesuai dengan tingkah laku rekan-rekan kerja Budi?"*

UEBA di industri SOC biasanya tidak berdiri sebagai kueri satuan, ia adalah sebuah **Platform Dasbor Utuh** (seperti Exabeam, Splunk UBA, atau Elastic Security Identity Dashboard). Ia menyedot setiap aktivitas log pengguna (Masuk, VPN, File Share, Printer, Email), dan melukis profil komprehensif dari setiap manusia dan perangkat di gedung Anda.

3.2 Membedakan Analitik User vs Entity

Huruf "U" dan "E" dalam UEBA menargetkan dua benda yang berbeda:

- **User (Pengguna):** Identitas manusia yang memiliki Nama dan *Password* (misal: `Budi.IT`). Manusia bergerak dari satu *laptop* ke *laptop* lain, masuk ke layanan *Cloud*, dan menggunakan *Smartphone*. ML melacak **Identitas** terlepas dari perangkat apa yang Budi pakai.
- **Entity (Entitas):** Benda mati non-manusia. Ini bisa berupa *Laptop* spesifik (MacBook-MKT-01), *Server Database*, Alamat IP *Router*, atau bahkan *Service Account* sistem (`SQLAdmin$`). Entitas harus memiliki rutinitas yang sangat kaku. Jika *Database Server* (Entitas) tiba-tiba mencoba melakukan *Browsing* (HTTP GET) ke situs *Reddit.com*, mesin ML UEBA akan berteriak karena entitas tersebut telah rusak / menyimpang.

3.3 Peer Group Profiling (Grup Rekan)

Mengevaluasi Budi terhadap masa lalunya sendiri (*Self-Profiling*) tidaklah cukup. Bagaimana jika sejak hari pertama Budi bekerja, dia memang sudah berniat jahat (*Malicious Insider*)? *Baseline*-nya sudah korup sejak awal.

Di sinilah kehebatan **Peer Group Profiling (Profil Rekan Sejawat)**. Mesin ML UEBA berintegrasi dengan *Active Directory / HR System* perusahaan Anda untuk mengetahui bahwa Budi ada di Departemen Keuangan (*Finance*).

Mesin mengelompokkan (*Cluster*) profil perilaku Budi dan membandingkannya (*Peer Analysis*) dengan 20 Karyawan Keuangan lainnya.

"Budi mengakses Folder Laporan Gaji (G:). Apakah ini anomali? Mari kita lihat rekannya. Oh, ternyata 18 dari 20 orang di Departemen Keuangan secara rutin membuka Folder (G:) tersebut. Jadi, tindakan Budi adalah Normal untuk grup rekannya. Abaikan peringatan."

Tanpa *Peer Profiling*, SIEM akan membanjiri SOC dengan *False Positives* setiap kali karyawan melakukan tugas baru yang sah (Legal) di departemennya.

3.4 Mekanika Risk Scoring (Skor Risiko)

Platform UEBA tidak meledakkan *Alert* (Peringatan Merah) pada setiap kesalahan kecil. Mereka menggunakan sistem **Akumulasi Skor Risiko (Risk Scoring)** dari skala 0 hingga 100.

KEJADIAN HARIAN (AKTIVITAS BUDI)	PENAMBAHAN SKOR RISIKO UEBA
Budi *login* dari rumah (VPN) di IP baru.	+15 (Anomali Ringan - Bisa jadi dari Kafe).
Budi gagal *login* sandi 2 kali, lalu berhasil.	+5 (Manusiawi, salah ketik).
Budi mencoba mengakses Server Produksi (Akses Ditolak).	+40 (Anomali Berat - Bukan wewenangnya).
Total Skor Harian Budi	**Skor 60 (Watchlist / Pemantauan)**

Analis SOC tidak merespons insiden "Gagal Login". Analis SOC melihat *Dashboard UEBA* yang telah diurutkan (*Sorted*) berdasarkan skor pengguna. Jika total skor Budi menyentuh **Ambang Batas 90**, barulah SOAR memicu peringatan insiden *Critical* dan mengunci akun Budi secara proaktif sebelum kerusakan terjadi.

3.5 Berburu Insider Threat (Ancaman Internal)

Serangan siber tidak selalu datang dari luar (Rusia/Cina). Seringkali musuh adalah karyawan Anda sendiri yang sakit hati (akan dipecat) atau berniat menjual rahasia dagang (**Insider Threat**).

Rule statis (KQL/SIEM biasa) hampir tidak mungkin menangkap *Insider* karena mereka menggunakan kredensial asli dan memiliki izin resmi dari kantor. Mereka "berhak" membuka fail rahasia tersebut.

UEBA mendeteksi *Insider* melalui model **Data Hoarding (Penimbunan Data)** dan **Flight Risk Behavior**. Model ML akan mendeteksi penyimpangan tajam dari *Baseline*: Seorang *Engineer* biasanya membaca 5 dokumen *Source Code* per hari. Selama seminggu terakhir gagasannya ditolak bosnya, ia tiba-tiba mengunduh (Membaca/Menggandakan) 4.500 dokumen *Source Code* dan mengakses situs *USB/Cloud Drive* pribadinya.

Volume, arah (*velocity*), dan penyimpangan dari rekan sejawatnya akan meroketkan Skor Risiko entitasnya menjadi 99, memicu isolasi otomatis HRD.

3.6 ML Mendeteksi Impossible Travel

Mendeteksi akun yang diambil alih (*Account Takeover*) karena pencurian *Password* menggunakan ML lebih superior daripada perhitungan kecepatan (*Velocity*) tradisional yang dibahas di dokumen ZTA.

Aturan lama untuk *Impossible Travel* (Perjalanan Tak Mungkin) mudah ditipu jika peretas menggunakan IP VPN di satu kota yang sama dengan korban. Model ML (UEBA) tidak sekadar melihat IP, melainkan mengevaluasi **Sinyal Konteks Jamak (Multi-Context Signals)**.

ML mengevaluasi: Budi berhasil masuk dari IP Jakarta. Namun ML sadar bahwa Budi SELALU masuk (*Baseline* historis) menggunakan perangkat *MacBook* ber-UA `Safari`, dari subnet *Indihome*. Hari ini, sesi masuk Budi di Jakarta menggunakan *Windows 10* dengan *UA* `Chrome`, dari ISP *Hosting Provider (DigitalOcean)*.

Kecerdasan algoritmik ini (*Unusual ISP + Unusual OS + Unusual Time*) akan mendikte UEBA untuk menambah skor risiko Budi sebesar +80 dan memaksanya melakukan validasi MFA (FIDO2) tingkat dua.

3.7 Anomali Working Hours (Waktu Kerja)

Model distribusi waktu (*Time of Day Analysis*) adalah fitur standar *Unsupervised Learning*. Jika *Active Directory* (AD) Anda mencatat ratusan ribu *Event ID 4624 (Logon)*, sistem akan memetakan jam aktivitas normal perusahaan (misal: 08:00 - 18:00).

Namun ML cukup cerdas untuk membuat model distribusi ini **secara independen untuk setiap individu (Per-User Profile)**.

Jika staf TI Server (*Sysadmin*) memang memiliki jadwal giliran (*Shift*) malam dan sering masuk di pukul 02:00 dini hari, sistem UEBA tidak akan memberikan peringatan kepada mereka. Tetapi jika staf *HRD* (yang *baseline*-nya tidak pernah *login* di atas jam 20:00 selama 2 tahun terakhir) tiba-tiba melakukan *Remote Desktop (RDP)* ke peladen *Payroll* (Gaji) pada pukul 03:00 pagi Hari Minggu, Anomali Jam Kerja (*Working Hour Anomaly*) akan terpicu secara mematikan.

3.8 Privileged Account Monitoring

UEBA memberikan perlakuan khusus kepada kelompok manusia paling berbahaya di perusahaan Anda: **Administrator TI (Domain Admins)**.

Karena mereka memiliki kunci ke seluruh kerajaan (*Servers, Firewalls*), satu kesalahan atau satu kompromi pada akun mereka berujung kiamat. UEBA memisahkan (*tagging*) akun mereka menjadi Entitas Berisiko Tinggi (*High-Value Assets / HVA*).

Ambang sensitivitas ML untuk grup Administrator diturunkan dengan drastis. Jika pengguna biasa salah sandi 3 kali akan mendapatkan penalti skor risiko 5, *Administrator* yang salah sandi 3 kali (atau menjalankan perintah `PowerShell` acak yang tidak pernah ia jalankan sebelumnya) akan mendapat penalti skor risiko 50.

Pendekatan pemantauan ketat (*Micro-Monitoring*) ini memastikan pergerakan lateral peretas yang berhasil mencuri tiket *Golden/Silver Ticket* (yang memalsukan diri sebagai Admin) tertangkap langsung oleh lensa anomali perilaku sistem.

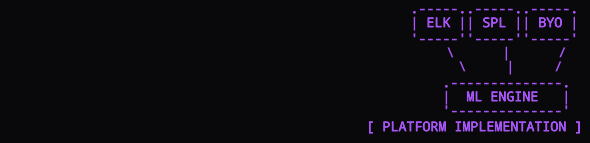
3.9 Sinergi UEBA dengan Zero Trust

Platform UEBA (Skor Risiko ML) bukanlah alat pencegahan fisik (*Firewall*). UEBA adalah instrumen Analitik (Deteksi). Untuk menghasilkan pertahanan otomatis, skor UEBA harus dikirim (diumpankan) ke **Policy Engine** dari *Zero Trust Architecture (ZTA)*.

Saat UEBA mendeteksi Budi melakukan *Data Hoarding*, skor risiko Budi berubah menjadi 95 (Critical). *API Gateway* UEBA segera mendorong pembaruan *JSON Payload* ke Identity Provider perusahaan (seperti Azure AD / Okta).

Detik itu juga, *Conditional Access Policy* ZTA Okta yang terus memantau Budi akan bereaksi: *"Skor Identitas Budi jatuh. Cabut semua sesi Token (*Revoke Sessions*) di Office 365, AWS, dan Salesforce, lalu paksa dia Logout paksa."*

Ini adalah wujud sempurna dari (**Continuous Adaptive Risk and Trust Assessment / CARTA**) rancangan Gartner, di mana ML UEBA bertindak sebagai mata analitik, dan ZTA bertindak sebagai pedang pengeksekusi.



BAGIAN IV

Implementasi Praktis ML
di Platform SIEM Enterprise

BAB 4: SIEM ML PRAKTIS

4.1 Ekosistem Elastic ML

Mari kita berpindah dari teori ke meja kerja *Security Engineer*. Jika tumpukan teknologi Anda adalah **Elastic Security (ELK Stack)**, Anda diberkati dengan mesin ML *Unsupervised* bawaan yang luar biasa. Mesin ini tidak memerlukan kode *Python* atau *Jupyter Notebook*, semuanya dikonfigurasi melalui antarmuka JSON yang disebut **Anomaly Detection Jobs**.

Di Elastic, sebuah *ML Job* berjalan layaknya peladen mikrolayanan (*Microservice*) kecil di latar belakang (dikelola oleh *Node Machine Learning* khusus). Ia terus-menerus mengunyah data log (*Datafeed*) yang masuk ke indeks (seperti indeks `logs-endpoint-*` atau `packetbeat-*`) secara *real-time* dan mencocokkannya dengan kurva matematika yang telah ia pelajari (Model *State*).

Hasil prediksinya—apakah sebuah log dinilai anomali atau tidak—ditulis ke dalam indeks sistem rahasia (biasanya bernama `.ml-anomalies-shared`) yang bisa ditelusuri menggunakan *Kibana Query Language (KQL)* biasa.

4.2 Mengonfigurasi Single Metric Job

Jenis *ML Job* paling dasar di Elastic adalah **Single Metric Job**. Sesuai namanya, ia hanya melacak 1 fungsi matematika (misalnya: Jumlah, Rata-rata, Tertinggi, Terendah) terhadap 1 jenis data (misalnya: Total Log *Login Failed*).

```
# Konfigurasi JSON API: Elastic ML Single Metric (Failed Logins Spike) { "job_id": "auth-failed-login-spike", "analysis_config": { "bucket_span": "15m", # Mengelompokkan analisis tiap 15 menit "detectors": [ { "function": "high_count" # Deteksi lonjakan yang sangat tinggi di atas normal } ] }, "data_description": { "time_field": "@timestamp" } }
```

Ini adalah perisai andalan anti-DDoS dan *Brute Force*. Jika biasanya perusahaan menerima 50 kegagalan masuk (*login failed*) per 15 menit, ML akan membentuk *Baseline* di angka 50. Jika tiba-tiba Elastic menerima 900 kegagalan (*high_count*) dari serangan *Credential Stuffing*, anomali langsung terpicu, tanpa Anda perlu menebak batas *Threshold* 900 tersebut secara manual.

4.3 Multi-Metric & Population Jobs

Keajaiban sebenarnya (tingkat menengah) terjadi di **Multi-Metric** dan **Population Jobs**. Jika *Single Metric* memantau 1 pipa data raksasa (seluruh kantor), *Multi-Metric* memecahnya dan melacak setiap pipa individu (misalnya: Melacak jumlah *Login* Gagal **UNTUK SETIAP** Pengguna secara terpisah).

```
# Elastic ML: Rare Process by User (Multi-Metric) "detectors": [ { "function": "rare", "by_field_name":
"process.name", "partition_field_name": "user.name" } ]
```

Pada model di atas, menggunakan `partition_field_name: user.name`, Elastic secara harfiah **menciptakan 5.000 model Machine Learning mini (Micro-models) secara mandiri di latar belakang** untuk setiap 5.000 karyawan Anda. ML ini akan melacak kebiasaan (*Baseline*) Budi, kebiasaan Siti, dan kebiasaan Joko secara terpisah dan presisi (ini adalah jantung UEBA).

4.4 Konsep Influencers di ML Elastic

Saat ML menembakkan peringatan (*Alert*): *"Terjadi anomali tinggi pada Bandwidth Jaringan"*, informasi ini kurang berguna bagi analis SOC. Kita tidak tahu siapa pelaku atau komputernya. Analis membutuhkan konteks (Investigasi).

Di Elastic ML, ada sebuah fitur krusial yang disebut **Influencers (Pemberi Pengaruh)**. Saat Anda mengonfigurasi *ML Job*, Anda mendefinisikan *Influencers* (misal: `source.ip`, `user.name`).

Saat lonjakan *Bandwidth* (Anomali) terjadi, mesin matematis akan membedah miliaran log di jendela waktu 15 menit tersebut, dan menunjuk (*Pinpoint*) entitas penyebabnya: *"Anomali Bandwidth 500GB ini dipengaruhi 99% oleh source.ip: 10.10.5.21 (Laptop Marketing)."* Fitur *Influencer* inilah yang mengubah perhitungan matematika yang abstrak menjadi *IoC (Indicator of Compromise)* yang dapat ditindaklanjuti secara taktis.

4.5 Splunk UBA (User Behavior Analytics)

Jika perusahaan Anda menggunakan ekosistem Splunk, analitik ML utama biasanya dilepaskan melalui produk khusus (*Add-on* yang berdiri sendiri) bernama **Splunk UBA**, bukan sekadar indeks di dalam *Splunk Enterprise*.

Berbeda dengan *Elastic ML* di mana *Engineer* harus secara eksplisit menulis spesifikasi metrik JSON, *Splunk UBA* (dan *Splunk Enterprise Security / ES*) menggunakan pendekatan *Pre-Packaged / Turn-key*.

Data log (*Network, Authentication, Endpoint*) yang telah dinormalisasi menggunakan model CIM (*Common Information Model*) milik Splunk, akan diumpankan (*Ingested*) secara massal ke peladen UBA. Di sana, algoritma *Data Science* yang sudah dipatenkan Splunk akan merangkai profil *Peer Group* (Kelompok Rekan) tanpa campur tangan kode (*code*) dari analis SOC. Fokus SOC dalam Splunk UBA adalah berburu pada layar *Dashboard Threat Scenarios* dan meninjau *Entity Risk Scores*, bukan merancang algoritma dari awal.

4.6 KQL: Kueri Indeks .ml-anomalies-*

Kembali ke Elastic: Bagaimana SOC menggabungkan *Alert Rule* tradisional dengan penemuan kecerdasan buatan? Jawabannya: **Kita membuat Rule yang membaca log dari mesin ML (Indeks Hasil Prediksi ML).**

Hasil dari seluruh prediksi probabilitas Elastic disimpan dalam indeks tersembunyi berawalan `.ml-anomalies-`.

```
/* SIEM KQL: Membuat Peringatan SOC berdasarkan Skor ML */ /* Mencari temuan di Indeks ML (Bukan log mentah) */ _index: ".ml-anomalies-*" AND result_type: "record" AND /* record_score adalah probabilitas anomali dari algoritma (0-100) */ record_score: >= 75 AND /* Hanya menargetkan ML Job khusus Exfiltration (Pencurian Data) */ job_id: "high-network-egress-outbound"
```

Aturan ini berjalan di atas SIEM. Jika mesin ML mendeteksi ada IP (*Influencer*) yang melanggar kurva matematika (menghasilkan `record_score: 90`), aturan KQL ini akan menangkap skor tersebut, mengonversinya menjadi Tiket Insiden (*Jira/ServiceNow*) agar segera diinvestigasi oleh manusia (Analis SOC).

4.7 Bring Your Own Model (BYOM)

Bagi tim SOC tingkat lanjut (*Maturity Level 4*) yang memiliki *Data Scientist* internal, model bawaan vendor SIEM sering kali kurang spesifik untuk kebutuhan khusus (misalnya, menambang deteksi *Fraud* Transaksi Perbankan). Platform modern (Elastic & Splunk) mendukung **Bring Your Own Model (BYOM)**.

Arsitektur BYOM:

1. Tim *Data Science* menarik (*Export*) data log mentah dari SIEM ke Jupyter Notebook / Python.
2. Mereka melatih algoritma *Deep Learning* (*Supervised PyTorch / Scikit-Learn*) atau NLP (*Natural Language Processing*) khusus pada *Cluster GPU* eksternal.
3. Model yang telah dilatih diekspor menjadi format matematika universal, seperti **PMML (Predictive Model Markup Language)** atau yang lebih modern **PyTorch TorchScript**.
4. Model PMML tersebut diunggah (diimpor) kembali ke dalam SIEM (Elastic).

Kini, saat log web masuk (*Ingest*), log tersebut akan dialirkan (*Piped*) melewati Model Khusus (*Custom PyTorch Model*) Anda terlebih dahulu untuk diproses dan di-*Tag* (diberi skor probabilitas *Malware/Fraud*), sebelum mendarat di *Dashboard* SOC.

4.8 NLP & Log Parsing Otomatis

Penerapan BYOM yang paling revolusioner di SOC bukanlah mencari Anomali Waktu (karena Elastic sudah menyediakannya), melainkan penggunaan **Natural Language Processing (NLP) / Neural Networks** untuk membedah teks (*Log Parsing*) yang rumit.

Alih-alih menulis 100 baris Regex (*Regular Expression*) yang rumit dan lambat untuk mengekstrak parameter dari Log Apache Web (yang sering meleset jika format lognya sedikit berubah), tim *Security* memasang Model NLP (seperti *DistilBERT* yang sudah di-*fine-tune* pada bahasa Log Komputer).

Model *Deep Learning* ini membaca baris log (*Raw Text*) seperti manusia membaca kalimat, memahami di mana IP, di mana URL, dan di mana Muatan Berbahaya (*Malicious Payload SQLi*), lalu secara otomatis mengekstrak (*Parse*) dan memberi kategori *Tagging* pada jutaan log per detik tanpa satu baris Regex pun. Ini adalah ujung tombak rekayasa data keamanan modern (*Modern Data Security Engineering*).



BAGIAN V

Operasionalisasi ML Alerts,
Tuning, & SOAR Integration

BAB 5: OPERASIONALISASI MODEL

5.1 Alert Fatigue di Dunia ML

Setelah Anda menyalakan 50 *ML Jobs* di SIEM, hari pertama akan terasa menakjubkan, hari ketiga akan menjadi neraka. Analis SOC Anda akan dihantam oleh fenomena **Alert Fatigue (Kelelahan Peringatan)**.

Alasan utamanya adalah *Over-Sensitivity* (Terlalu Sensitif). Karena model matematis (*Unsupervised*) menganggap segala sesuatu yang jarang (*Rare*) sebagai Anomali, dan di lingkungan perusahaan besar selalu ada hal *Rare* yang legal setiap hari (misalnya staf TI sedang menguji skrip otomatisasi baru).

Jika setiap peringatan ML (dengan Skor > 50) langsung membangkitkan (*Trigger*) Panggilan Telepon ke HP *On-Call Analyst* di tengah malam (*PagerDuty*), analis Anda akan *Burnout* (Kelelahan) dalam seminggu, dan mulai mengabaikan seluruh sistem ML tersebut (kehilangan kepercayaan pada alat). Kita butuh penyesuaian (*Tuning*).

5.2 Tuning Model & Feedback Loops

ML yang baik membutuhkan siklus umpan balik (*Feedback Loop*) dari manusia. Analis SOC tidak boleh hanya membaca dan menutup tiket. Jika peringatan ML tentang lonjakan masuk VPN (*VPN Login Spikes*) ternyata disebabkan oleh skrip sistem TI untuk *Monitoring*, analis harus "mengajari" mesin.

Dalam Elastic ML, ini dilakukan (meski terbatas) dengan mengedit aturan *Rules/Filters* dalam *Job* tersebut, atau menggunakan fitur penandaan kalender (*Calendars/Suppression*).

Di platform UEBA yang lebih maju, analis secara harfiah menekan tombol *Thumbs Down* (Jempol ke Bawah / Tidak Berguna) atau *Thumbs Up* (Berguna) pada layar Peringatan *False Positive*. Algoritma (di latar belakang) menyesuaikan beban kalkulasinya (*Weight Adjustment*) untuk mengurangi sensitivitas pada parameter spesifik tersebut untuk entitas tersebut di masa mendatang. **Inilah kolaborasi Manusia dan Mesin (Human-in-the-Loop AI).**

5.3 Suppression Windows (Jeda Pemeliharaan)

Ancaman terbesar terhadap integritas (kewarasan) model Waktu-Deret (*Time-Series Baseline*) adalah Pemeliharaan IT Berjadwal (*Scheduled IT Maintenance*).

Jika pada Malam Tahun Baru, tim *Server* melakukan *Patching* (Pembaruan) massal, me-*restart* semua 500 *Server Database* serentak, yang menghasilkan lonjakan *Logoff/Logon* yang masif. *ML Job* akan berteriak karena metrik meroket (Skor 100), dan parahnya, ML akan salah mempelajari (*Poisoned Learning*) kejadian masif tersebut sebagai "Hal Normal Baru" untuk *Baseline* Malam Tahun Baru di tahun-tahun mendatang!

Solusi Arsitek SOC adalah: **Suppression Windows (Jendela Kalender ML)**. Anda memasukkan Jadwal Pemeliharaan TI ke Kalender SIEM. Saat waktu tersebut tiba, *ML Job* akan menghentikan (*Pause*) proses pembelajaran (*Learning*) dan menahan pembentukan peringatan (*Alerting*), memastikan profil *Baseline* tetap murni dan tidak terkontaminasi oleh ledakan aktivitas legal.

5.4 Integrasi ML Risk Score dengan SOAR

Puncak kematangan operasi (*Maturity Level 5*) tercapai saat Peringatan ML (*ML Alerts*) tidak lagi dibaca oleh manusia, melainkan dieksekusi langsung oleh Mesin SOAR (*Security Orchestration, Automation and Response*).

Karena peringatan ML tidak pasti (probabilistik), SOAR membutuhkan **Decision Matrix** (Matriks Keputusan) berbasis Ambang Kepercayaan (*Confidence/Risk Score Threshold*).

```
# Pseudo-Logic: SOAR Playbook berbasis ML (Data Exfiltration) Trigger: Alert Diterima dari Elastic ML (Job: Exfil_Detection) Condition 1 (Score 50-74): # Anomali Ringan - SOAR mengirim Pesan Slack ke Analis L1 untuk pengecekan Manual. Condition 2 (Score 75-89): # Anomali Berat - SOAR membuat Tiket Critical ServiceNow. - SOAR secara otomatis memerintahkan EDR untuk menarik (Extract) file Memory Dump dari laptop pelaku, lalu menunggu keputusan analis. Condition 3 (Score 90-100): # Absolute Certainty (Pasti Bahaya) - SOAR langsung memanggil API Firewall/EDR untuk Isolate Network Host (Putus internet). - Hubungi Manajemen via Panggilan Darurat (PagerDuty).
```

5.5 Masa Depan: Dari ML menuju GenAI (LLMs)

Machine Learning Unsupervised telah memecahkan masalah menemukan Jarum di Tumpukan Jerami (*Anomaly Detection*). Masalah baru hari ini adalah: Saat jarum itu (*Alert*) ditemukan, menganalisis mengapa ia berbahaya (*Triage/Investigation*) masih membutuhkan 45 menit pengerjaan otak analis manusia.

Revolusi selanjutnya di SOC adalah **Generative AI (Large Language Models / LLM)**.

Jika *ML Job* mendeteksi anomali pada `cmd.exe` (Bab 2.6), sistem *Security Copilot* (berbasis LLM khusus/terisolasi) akan secara otomatis menelan *Payload Alert* tersebut, membaca dokumentasi ancaman MITRE ATT&CK terbaru, mem-*parsing* KQL dengan bahasa alami, dan menulis sebuah ringkasan naratif layaknya manusia di tiket: *"Analis, ini adalah serangan Phishing Emotet varian baru. Saya telah menemukan rantai prosesnya. Haruskah saya memblokirnya sekarang? [Ya/Tidak]"*.

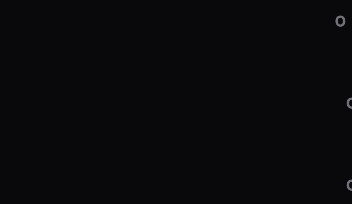
Alat deteksi ML akan dipadukan secara organik dengan Agen LLM (*AI Agents*), mengubah analis SOC L1 dari sekadar "Pembaca Log" menjadi "Pengawas Operator AI (*AI Supervisors*)".

GLOSARIUM ML SECOPS (A-M)

TERMINOLOGI	DEFINISI KONSEPTUAL SIEM
Anomaly Baseline	Profil matematis perilaku "Normal" yang dipelajari mesin (selama 14-30 hari) untuk menjadi titik acuan dalam mendeteksi ketidakwajaran masa depan.
BYOM	*Bring Your Own Model*. Kemampuan memasukkan model AI eksternal yang Anda latih sendiri (Python/PyTorch) ke dalam jalur masuk (*Pipeline*) SIEM komersial.
Clustering	Algoritma pengelompokan (*Unsupervised*) yang mencari log yang saling mirip, sering digunakan untuk menemukan *Outliers* (pencilan).
DGA	*Domain Generation Algorithm*. Taktik *malware* menghasilkan domain acak (misal `as8dzk.info`). Deteksi ML (Klasifikasi) menggunakan skor Entropi digunakan untuk menangkalnya.
Feature Engineering	Seni Data Sains untuk mengekstrak atau menghitung nilai numerik baru (Fitur) dari log teks mentah sebelum dimasukkan ke dalam model ML.

GLOSARIUM ML SECOPS (N-Z)

TERMINOLOGI	DEFINISI KONSEPTUAL SIEM
Influencers	(Dalam Elastic ML). Fitur penunjukan atribut kunci (misal: `user.name`) yang menjadi penyebab paling dominan atas terjadinya sebuah ledakan anomali.
Insider Threat	Ancaman internal oleh karyawan resmi (yang memiliki hak akses). Sangat sulit dideteksi dengan KQL biasa, membutuhkan analitik UEBA (Data Hoarding).
Outliers	Log, *Event*, atau Entitas (Pencilan) yang jatuh sangat jauh dari kerumunan kelompok rekannya (*Cluster*) dalam ruang matematis.
Time-Series Analysis	Analisis data berdasarkan urutan waktu. ML menggunakannya untuk mendeteksi lonjakan volume (*Volumetric Spikes*) yang menyimpang dari tren musiman.
UEBA	*User and Entity Behavior Analytics*. Modul/Platform AI yang melacak manusia dan mesin (*Endpoints*), membandingkannya dengan sejarah (*Baseline*) dan kelompok sejawat (*Peer Profiling*).



> Aturan statis hanya akan menangkap musuh kemarin.
> Untuk menangkap penyerang esok hari, Anda harus
> mengajarkan mesin tentang makna kewajaran.

The Neural Defense Architecture

© 2026 All rights reserved.
SOC Data Science & Engineering.